

Lista 2

Aneta Przydróżna

Regresja grzbietowa

Generuję macierz $X_{1000 \times 950}$, tak aby $X'X=I$, wektor predyktorów z k pierwszymi wyrazami równymi 3, resztą równą 0 oraz wektor szumu ϵ z rozkładu $N(0, I)$.

• Macierz X jest ortonormalna, zatem optymalna $\lambda = \frac{950 \cdot \sigma^2}{\|\beta\|^2}$ najlepiej minimalizuje $MSE(\hat{\beta})$. Poniżej znajdują się λ dla $k=\{20,100,200\}$ oraz wybrane statystyki policzone z użyciem tego estymatora.

##	lambda	Obciążenie	Wariancja	MSE	moc
## 20	5.278	127.222	24.105	151.327	0.20
## 100	1.056	237.327	224.836	462.162	0.18
## 200	0.528	214.810	407.008	621.818	0.19

Z kolejnymi istotnymi zmiennymi objaśniającymi, optymalna lambda jest coraz mniejsza.

- $Bias^2(\hat{\beta}) = \frac{\lambda^2 \cdot \|\hat{\beta}\|^2}{(1+\lambda)^2}$
- $Var(\hat{\beta}) = \frac{\sigma^2 \cdot 950}{(1+\lambda)^2}$
- $MSE(\hat{\beta}) = Bias^2(\hat{\beta}) + Var(\hat{\beta})$
- Wartość krytyczna $C = \frac{\sigma}{1+\lambda} \cdot \Phi^{-1}(1 - \frac{\alpha}{2 \cdot 950})$

Używamy tej wartości aby testować hipotezę zerową, że $\beta_i=0$, dla $i=\{1,...,950\}$. Gdy $|\hat{\beta}_i^R| > C$, odrzucamy H_0 . Wskaźnik błędu $FWER \leq \alpha = 0.1$ to prawdopodobieństwo popełnienia jednego lub większej liczby fałszywych odkryć, w tym przypadku na poziomie istotności $\alpha = 0.1$.

Podana moc wskazuje stosunek liczby prawdziwych odkryć, a niezerowych parametrów. We wszystkich przypadkach znajduje się bliżej zera niż jedynki, co świadczy o nie za dobrym działaniu wskaźnika. Problem związany z poprawką Bonferroniego jest taki, że ograniczając liczbą fałszywych pozytywów przez obniżenie progu p-wartości przyjmujemy niepoprawne hipotezy zerowe, a więc nie wykrywamy istotnych cech.

Dla metody najmniejszych kwadratów mamy następujące parametry:

- Estymator β jest nieobciążony zatem $Bias^2(\hat{\beta}) = 0$
- $Cov(\hat{\beta}) = \sigma^2 \cdot I = I$
- $Var(\hat{\beta}) = MSE(\hat{\beta}) = Tr(Cov(\hat{\beta})) = 950$

Empiryczne wyniki dla powyższych parametrów:

[1] "Ridge"

##	Obciążenie	Wariancja	MSE	Moc
## 20	127.410	23.600	151.442	0.187
## 100	238.567	220.121	463.271	0.196

```
## 200      219.403    398.473 619.818 0.191
## [1] "OLS"
##      Obciążenie Wariancja      MSE    Moc
## 20      4.592    947.430 952.3940 0.193
## 100     4.623    946.983 945.2341 0.185
## 200     4.935    949.324 953.5630 0.201
```

Wyliczone teoretycznie i empirycznie dane w obu przypadkach są bardzo podobne, natomiast różnią się między sobą. Korzystając z metody najmniejszych kwadratów powinniśmy spodziewać się zerowego obciążenia, natomiast pojawiło się ono, ze względu na liczbę eksperymentów, lecz bardzo niewielkie. W przypadku regresji grzbietowej dla dużych k , wartości obciążenia przekraczają nawet 200. Koszt tego metoda osiąga znacznie lepsze wariancje i MSE. Najlepiej widać to w przypadku, gdy $k=20$, gdy wariancja Ridge dla wektora estymatora β jest niemalże 40-krotnie mniejsza, MSE 6-krotnie. Ridge reaguje również na ilość istotnych parametrów, w OLS wszystkie parametry są zbliżone, niezależnie od k . Ogólnie można stwierdzić, że metoda regresji grzbietowej radzi sobie lepiej niż metoda najmniejszych kwadratów.